

Optimización de la función $f(x, y) = x^4 - 4x^3 + 4x + y^2$

Nombre: Ruben Martinez Rojas
Grupo: C311

December 2, 2025

1 Modelos a analizar

La función a analizar es:

$$f(x, y) = x^4 - 4x^3 + 4x + y^2$$

2 Análisis de los modelos

2.1 Existencia de solución

Para estudiar la existencia de puntos óptimos, se calcularán los ceros del vector gradiente de la función, dado que todo mínimo (o máximo) local diferenciable debe satisfacer

$$\nabla f(x, y) = 0$$

. El gradiente está dado por el vector de derivadas parciales:

$$\nabla f(x, y) = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix} = \begin{bmatrix} 4x^3 - 12x^2 + 4 \\ 2y \end{bmatrix}$$

Para encontrarlos, igualamos cada componente del gradiente a cero:

$$\frac{\partial f}{\partial x} = 4x^3 - 12x^2 + 4 = 0, \quad \frac{\partial f}{\partial y} = 2y = 0.$$

De la ecuación en y se obtiene directamente:

$$y = 0.$$

Para la ecuación en x , simplificamos dividiendo entre 4:

$$x^3 - 3x^2 + 1 = 0.$$

Esta ecuación cónica puede tener una, dos o tres raíces reales.

2.2 Convexidad

La matriz Hessiana de la función

$$f(x, y) = x^4 - 4x^3 + 4x + y^2$$

es:

$$H(x, y) = \begin{bmatrix} 12x^2 - 24x & 0 \\ 0 & 2 \end{bmatrix}.$$

Para que la función sea convexa, $H(x, y)$ debe ser definida positiva. Vemos que no lo es para todos los valores de x , por lo tanto la función no es convexa globalmente. Sin embargo, se puede analizar localmente para regiones donde $12x^2 - 24x > 0$, es decir, para $x > 2$ o $x < 0$. Pues en estas regiones donde la Hessiana es definida positiva, la función tiene curvatura positiva en todas las direcciones, lo cual implica que alrededor del punto es similar a un tazón. En estas regiones la curvatura de la función no cambia de signo y las direcciones de descenso son estables. Por ello, los métodos de Gradiente, Newton y Quasi-Newton tienden a converger rápidamente hacia un mínimo local.

En cambio, cuando la Hessiana posee valores negativos (como ocurre en la región $0 < x < 2$), la función presenta curvatura negativa en alguna dirección, generando zonas tipo silla de montar. Allí los métodos de optimización tienen comportamientos menos predecibles: el método de Gradiente puede oscilar o avanzar muy lentamente debido a cambios abruptos en la pendiente, mientras que el método de Newton puede producir pasos en direcciones incorrectas, dirigirse hacia un máximo local o incluso divergir por completo. Esto se debe a que la inversión del Hessiano introduce direcciones inestables cuando existen eigenvalores negativos.

Por este motivo, en regiones no convexas es más probable que los métodos queden atrapados en mínimos locales o se comporten de manera errática, y se vuelve necesario usar técnicas globales como Multi-start para explorar distintas zonas del dominio.

La estrategia Multi-start consiste en ejecutar un algoritmo de búsqueda de mínimo local desde muchos puntos iniciales distintos. Cada ejecución puede converger a un mínimo local diferente, y al comparar los valores finales se elige la mejor solución como candidato al mínimo global. Este enfoque es especialmente útil para funciones no convexas como la presente, ya que ayuda a evitar quedar atrapado en mínimos locales subóptimos. La efectividad del método depende tanto de la distribución de los puntos iniciales como de la capacidad del algoritmo local para converger rápidamente hacia un mínimo en la región donde se inicia el proceso.

2.3 Algoritmos de Optimización

Dado que la función

$$f(x, y) = x^4 - 4x^3 + 4x + y^2$$

no es convexa globalmente, es importante elegir algoritmos adecuados y considerar estrategias de múltiples puntos iniciales para buscar un mínimo global.

1. Método de Descenso por Gradiente (explicación detallada)

Descripción corta. El método de Gradiente es un método iterativo que actualiza la variable en la dirección de máximo descenso local:

$$x_{k+1} = x_k - \alpha \nabla f(x_k),$$

donde $\alpha > 0$ es el *learning rate* (tasa de paso) y $\nabla f(x_k)$ es el gradiente en x_k .

Pseudocódigo:

```
Elegir x0, tolerancia epsilon, paso alpha
Para k = 0,1,2,...:
    Calcular gradiente gk = grad(f)(xk)
    Si ||gk|| < epsilon: terminar
    Actualizar x_{k+1} = xk - alpha * gk
Fin
```

Funcionamiento paso a paso.

1. **Inicialización:** Se elige un punto inicial x_0 , una tolerancia ε y un número máximo de iteraciones K_{\max} . También se selecciona un valor inicial del learning rate α , pero antes de fijarlo se realizan pruebas con varios valores para determinar cuál es el más adecuado en cada región del dominio.
2. **Cálculo del gradiente:** En cada iteración k se calcula el gradiente $g_k = \nabla f(x_k)$. El gradiente señala la dirección de *máximo incremento* de la función. Por tanto, su opuesto $-g_k$ indica la dirección de *máximo descenso local*, que es la dirección óptima para reducir el valor de la función.
3. **Actualización:** El punto se desplaza en la dirección de descenso mediante

$$x_{k+1} = x_k - \alpha g_k.$$

Este paso ajusta la posición según la magnitud del gradiente y el valor elegido de α , controlando qué tan grande es el avance en la iteración.

4. **Criterio de parada:** Se detiene el algoritmo cuando se cumple alguna de las siguientes condiciones:

- **Cambio pequeño entre iteraciones:**

$$\|x_{k+1} - x_k\| < \varepsilon.$$

Esto indica que el algoritmo ha entrado en una zona donde la mejora por iteración es insignificante (estancamiento). Este criterio es útil incluso cuando el gradiente no disminuye estrictamente, pero las actualizaciones se vuelven muy pequeñas, señalando convergencia práctica.

- **Tope de iteraciones K_{\max} :** Garantiza seguridad computacional, evitando ciclos infinitos en casos de divergencia o estancamiento. Además, permite comparar el costo computacional entre configuraciones distintas del algoritmo.

5. **Iterar:** El proceso se repite hasta cumplir alguno de los criterios de parada anteriores.

Influencia de cada parámetro:

- **Learning rate α :** controla el tamaño del paso en cada iteración.
 - α **muy pequeño:** garantiza estabilidad y convergencia segura, pero requiere muchas iteraciones.
 - α **intermedio:** proporciona un equilibrio entre velocidad y estabilidad.
 - α **grande:** puede producir oscilaciones, saltarse el mínimo o incluso divergir, especialmente en regiones con alta curvatura.
- **Tolerancia ε :** define el nivel de precisión. Valores más pequeños exigen mayores iteraciones.
- **Máximo de iteraciones K_{\max} :** evita ciclos indefinidos y permite controlar el costo computacional.
- **Punto inicial x_0 :** en funciones no convexas determina a qué mínimo local converge el algoritmo; por ello se evalúan puntos iniciales en distintas regiones.

Protocolo experimental para seleccionar el mejor learning rate

Antes de ejecutar el algoritmo de descenso por gradiente de manera definitiva, se realizan pruebas en cada región del espacio utilizando múltiples puntos iniciales aleatorios. Cada uno de estos puntos se evalúa con distintos valores de learning rate, con el objetivo de identificar qué α converge con mayor estabilidad, comparar velocidad (número de iteraciones), evitar valores que generen divergencias, determinar el valor más adecuado de α para cada región.

Cada ejecución produce un registro que se almacena en el archivo `resultados_gradiente.csv`, el cual contiene la siguiente información:

Columna	Descripción	Utilidad
<code>x0</code>	Punto inicial $[x, y]$ desde donde comienza la búsqueda	Permite clasificar la región: $x > 2$, $x < 0$, $0 < x < 2$
<code>lr</code>	Learning rate usado en la ejecución	Comparar cuál LR funciona mejor en cada región
<code>x_final</code>	Punto obtenido al finalizar las iteraciones	Determinar el punto de convergencia
<code>f_final</code>	Valor de $f(x)$ en el punto final	Medir cuán bueno es el resultado
<code>num_iter</code>	Iteraciones necesarias para converger	Evaluar velocidad y estabilidad del algoritmo

Table 1: Contenido del archivo `resultados_gradiente.csv`

Este archivo se utiliza posteriormente para analizar de forma sistemática cuál learning rate es el más eficiente y estable en cada región del espacio.

Objetivo. Encontrar, por cada región del espacio ($x > 2$, $x < 0$, $0 < x < 2$), qué valores de α dan el mejor balance entre *estabilidad* y *rapidez* para el Descenso por Gradiente en la función estudiada.

Procedimiento experimental recomendado (paso a paso).

1. **Definir regiones y puntos iniciales:** elegir varios puntos iniciales por región (ej.: 5 aleatorios por región) y además forzar algunos con $y = 0$ si quieras observar el efecto en la componente y .
2. **Elegir candidatos de LR:** formar una lista de α candidatos $\{0.001, 0.005, 0.01, 0.05, 0.1\}$.
 - **Empieza pequeño:** la lista incluye 0.001 y 0.005 para cubrir estabilidad fuerte.
 - **Incluye valores típicos:** 0.01 suele funcionar bien en funciones suaves y sirve como referencia.
 - **Explora valores más grandes:** 0.05 y 0.1 para detectar si es posible acelerar; si provocan oscilación se descartan.
 - **Motivación teórica:** la presencia de términos de cuarto grado (x^4) implica que la curvatura puede crecer rápido con x , por eso no conviene empezar con LR demasiado grande.
3. **Para cada región y cada punto inicial:** ejecutar el descenso por gradiente para cada α y guardar las métricas.

Descenso por Gradiente con Búsqueda en Línea (Backtracking Armijo)

Pseudocódigo.

Gradient Descent con Backtracking Armijo

Entradas:

x0	-> punto inicial
epsilon	-> tolerancia
Kmax	-> máximo número de iteraciones
alpha0	-> paso inicial (típicamente 1)
beta	-> factor de reducción ($0 < \beta < 1$)
c	-> constante de Armijo (típicamente $1e-4$)

x = x0

Guardar x en historial

Para k = 0, 1, ..., Kmax:

1. Calcular gradiente $g = \text{grad}_f(x)$
2. Si $\text{norm}(g) < \epsilon$:
 terminar
3. Backtracking Armijo:
 $\alpha = \alpha_0$
 $f_x = f(x)$
 $g_{\text{norm_sq}} = \text{dot}(g, g)$

```

Mientras f(x - alpha*g) > fx - c*alpha*g_norm_sq:
    alpha = beta * alpha

```

4. Actualizar:

```
x_new = x - alpha*g
```

5. Guardar x_{new} en historial

6. Si $\text{norm}(x_{\text{new}} - x) < \epsilon$:
 terminar

7. $x = x_{\text{new}}$

Fin Para

Salida:

```
x final y el historial de iteraciones
```

Explicación Detallada de la Condición de Armijo

¿Qué es la condición de Armijo? La **condición de Armijo** (también llamada *regla de suficiente descenso*) es una desigualdad que verifica si el paso elegido produce una reducción “adecuada” en el valor de la función objetivo. Matemáticamente, para un punto x_k , dirección de descenso $d_k = -\nabla f(x_k)$ y paso $\alpha > 0$, la condición es:

$$f(x_k + \alpha d_k) \leq f(x_k) + c \cdot \alpha \nabla f(x_k)^T d_k$$

Para **descenso por gradiente** donde $d_k = -g_k$ (con $g_k = \nabla f(x_k)$), esta desigualdad se convierte en:

$$f(x_k - \alpha g_k) \leq f(x_k) - c\alpha \|g_k\|^2$$

donde:

- $0 < c < 1$ (típicamente $c \approx 10^{-4}$)
- α es el tamaño de paso que estamos probando
- $\|g_k\|^2 = \nabla f(x_k)^T g_k$ (producto punto del gradiente consigo mismo)

¿Por qué al cumplirse la condición el paso es “seguro”? Cuando se cumple la condición de Armijo, garantizamos:

1. Descenso suficiente

La reducción en f es al menos una fracción c de lo que predice la aproximación lineal:

$$f(x_k) - f(x_{k+1}) \geq c\alpha \|g_k\|^2 > 0$$

Como $\|g_k\|^2 > 0$ (si no estamos en un punto estacionario), la función *decrece estrictamente*.

2. Monotonidad

La secuencia $\{f(x_k)\}$ es estrictamente decreciente.

3. Acotación del paso

El α aceptado no es excesivamente grande, evitando oscilaciones.

4. Convergencia global (bajo condiciones)

Para funciones con gradiente Lipschitz continuo, el backtracking de Armijo garantiza que eventualmente se encontrará un α que satisface la condición, y el método convergerá a un punto estacionario.

Explicación paso a paso del algoritmo.

1. **Inicialización.** Se parte de un punto inicial x_0 . También se establece una tolerancia ε y un máximo de iteraciones K_{\max} .

El historial guarda las posiciones del algoritmo para poder estudiar la trayectoria posterior.

2. **Cálculo del gradiente.** En cada iteración se evalúa:

$$g_k = \nabla f(x_k).$$

El gradiente indica la dirección de mayor incremento local de la función; por lo tanto, el descenso debe hacerse en la dirección opuesta.

3. **Criterio de parada por gradiente pequeño.** Si

$$\|g_k\| < \varepsilon,$$

entonces la función es prácticamente plana alrededor del punto actual, lo cual indica que se alcanzó un punto cercano a un mínimo.

4. **Cálculo dinámico del paso α mediante Backtracking Armijo.** En lugar de usar un valor fijo de *learning rate*, se escoge un paso que garantice una disminución suficiente en la función.

- Se comienza con $\alpha_0 = 1$.
- Se comprueba la condición de Armijo:

$$f(x - \alpha g_k) \leq f(x) - c \alpha \|g_k\|^2.$$

- Si la condición no se cumple, el paso se reduce multiplicando por β :

$$\alpha \leftarrow \beta \alpha, \quad 0 < \beta < 1.$$

- Este proceso continúa hasta que el paso sea seguro y produzca una reducción adecuada.

La búsqueda en línea garantiza que:

- nunca se toma un paso demasiado grande que cause divergencia,

- tampoco se necesita un α excesivamente pequeño que ralentice el algoritmo.

5. **Actualización del punto.** Una vez determinado el paso adecuado se realiza:

$$x_{k+1} = x_k - \alpha g_k.$$

La magnitud del desplazamiento se ajusta dinámicamente según la curvatura local detectada por Armijo.

6. **Criterio de parada por cambio pequeño entre iteraciones.** Si

$$\|x_{k+1} - x_k\| < \varepsilon,$$

entonces se concluye que el algoritmo está suficientemente estabilizado y no vale la pena continuar.

7. **Iteración.** Se repite el proceso utilizando x_{k+1} como nuevo punto de partida.

3 Comparación de Resultados y Graficación

3.1 Experimentos

Se realizaron experimentos utilizando los tres algoritmos: Descenso por Gradiente, Newton y Quasi-Newton (BFGS) sobre la función

$$f(x, y) = x^4 - 4x^3 + 4x + y^2$$

partiendo de múltiples puntos iniciales (**Multi-start**) para explorar diferentes regiones de la función y evaluar la convergencia local y global.

3.2 Criterios de Comparación

Los resultados se comparan considerando:

- Número de iteraciones hasta convergencia.
- Tiempo de cómputo (si se dispone).
- Valor final de la función $f(x, y)$.
- Sensibilidad al punto inicial.
- Trayectorias de iteración en el plano (x, y) .

3.3 Observaciones

- **Descenso por Gradiente:** converge más lentamente, especialmente si el punto inicial está cerca de regiones de curvatura plana o mínima local no global.
- **Método de Newton:** converge muy rápido cerca de mínimos locales con Hessiana positiva definida, pero puede fallar si el Hessiano es indefinido.
- **Quasi-Newton (BFGS):** balancea velocidad y estabilidad, evitando el cálculo directo del Hessiano, con convergencia superlineal en regiones locales.
- **Multi-start:** aumenta significativamente la probabilidad de encontrar el mínimo global, explorando varias regiones de la función no convexa.

3.4 Graficación de la Función y Trayectorias

Para visualizar la convergencia de los algoritmos se pueden utilizar gráficos de contorno de la función y superponer la trayectoria de iteraciones de cada algoritmo:

Pseudocódigo para graficar trayectorias:

Crear una malla de puntos (X, Y) para evaluar $f(X, Y)$

Calcular $Z = f(X, Y)$

Dibujar contornos de Z

Para cada algoritmo:

 Obtener historial de puntos iterativos $[x_k, y_k]$

 Trazar línea conectando los puntos del historial

Añadir leyenda y etiquetas

3.5 Resultados Esperados

- Las trayectorias muestran cómo cada algoritmo se aproxima a diferentes mínimos locales.
- Multi-start permite que al menos uno de los algoritmos alcance el mínimo global.
- Descenso por Gradiente puede requerir más iteraciones que Newton o BFGS.

3.6 Figura Ejemplo

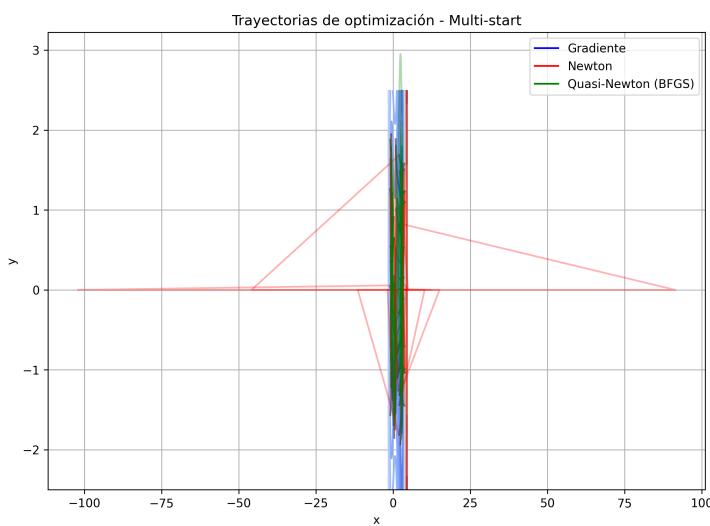


Figure 1: Contorno de $f(x, y)$ con trayectorias de los algoritmos desde múltiples puntos iniciales.

4 Conclusiones

- El método de Newton converge más rápido localmente, pero requiere cálculo del Hessiano.

- El descenso por gradiente es más simple, pero puede necesitar más pasos.
- Quasi-Newton (BFGS) combina velocidad y menor cálculo de derivadas.